



WEEKLY UPDATE • WEEK 07

고객 문의를 안전한 안내와 상담으로 연결하다

— 2026.08.24 — 08.28 4TEAM

이번 주 발표 순서

- | | | |
|----|------------------------|-------|
| 01 | WaterBridge가 해결하는 문제 | 03 |
| 02 | 이번 주 핵심 변화 | 04 |
| 03 | 3-Agent와 맥락정리 Agent 흐름 | 05—06 |
| 04 | 검색·화면·운영 변화 | 07—08 |
| 05 | 실험 업데이트와 현재 진행 | 09—11 |

WaterBridge는 고객 문의를 안전한 안내 또는 상담으로 연결한다

고객이 정수기 이상 증상을 입력하면 공식 문서에서 근거를 찾고, 안전하게 안내할 수 없는 경우에는 사람에게 넘긴다.



핵심 원칙

위험하거나 공식 근거가 부족하면 AI가 임의로 자가조치를 만들지 않는다.

이번 주에는 AI 답변이 실제 서비스로 이어지는 네 연결 고리를 보완했다

AI가 답변만 만드는 단계를 넘어
고객과 상담사에게 전달되는 흐름을 연결했다.

- 01 **안전 분기** — 바로 안내·사람 검토·상담 연결을 위험도별로 분리
- 02 **상담 맥락** — 고객 답변과 수행 행동을 상담사가 이해하기 쉽게 정리
- 03 **사용자 접점** — Mobile·Web을 실제 Backend 계약과 AWS 환경에 정합화
- 04 **운영 안정성** — 태그 배포·읽기 전용 데이터·검증 Gate를 보강

이번 주 방향 기능 수를 늘리기보다 “잘못 안내하지 않고, 필요하면 사람에게 정확히 넘기는가”에 집중했다.

기존 3-Agent 분석 뒤에 상담용 맥락정리 Agent를 조건부로 추가했다

기본 분석 흐름 · 한 Process에서 순차 실행

AGENT 01

증상 이해

고객 표현을 구조화하고 위험 신호·추가 질문을 찾는다.



AGENT 02

공식 근거 검색

제품과 증상에 맞는 검증 문서를 검색하고 근거를 선별한다.



AGENT 03

안내 판단

Safety와 근거를 바탕으로 안내·대기·상담 필요를 결정한다.

일반 안내·추가 질문·첫 사람 검토

기존 3-Agent 결과를 그대로 사용

맥락정리 Agent는 호출하지 않는다.

실제 상담 Handoff가 결정된 경우만

맥락정리 Agent → 상담사

문진 답변·고객 행동·승인 근거를 상담용 요약으로 정리해 Handoff v2에 담는다.

핵심 변화 상시 4-Agent가 아니라, 기존 3-Agent 분석에 “상담 전용 조건부 Agent”가 추가됐다.

AI 답변은 위험도에 따라 바로 안내·사람 검토·상담 연결로 나뉜다

일반

공식 근거로 바로 안내

고객에게 전달

제품과 증상에 맞는 근거가 있고 상담이 필요하지 않을 때만 자가 안내를 제공한다.

주의

전송 전 사람이 검토

승인 · 수정 · 거절

AI 초안을 바로 보여주지 않고 담당자가 확인한 결과만 고객에게 전달한다.

위험 · 근거 부족

상담사에게 연결

맥락정리 Agent 실행

위험 신호와 고객 답변·행동을 정리해 상담사가 바로 이어서 대응할 수 있게 한다.

실패 처리 맥락 요약이 실패해도 기존 상담 연결은 유지하며, 자동 안내로 되돌리지 않는다.

검색 결과를 믿을 수 있도록 답변 근거와 평가 기준을 좁혔다

ANSWER EVIDENCE

공식 문서의 검증된 작은 단위만 답변 근거로 사용

원문 페이지 전체를 그대로 답변에 쓰지 않고, 제품·증상과 직접 관련된 검증 문장만 선별한다.

잘못된 범위 차단

해당 제품 매뉴얼로 답할 수 없는 질문은 검색 전에 막는다.

질문 표현 보완

“물이 약하게 나와요”처럼 다양한 표현을 보완하되 공식 문서는 바꾸지 않는다.

같은 정답지·채점 기준

검색 실험과 개발 도구가 동일한 Evidence 기준으로 결과를 비교한다.

검증 범위 구분

Local 진단과 실제 pgvector·Provider·서비스 E2E 결과를 따로 보고한다.

실험 결론 전체 매뉴얼 자동 청킹은 Parent-Child-256, 임베딩은 GTE가 개발 단계 기준 우세했다. 상세 수치는 9·10페이지에서 비교한다.

고객·상담사 화면과 배포 절차를 하나의 서비스 흐름으로 맞췄다

고객 Mobile

- 개발용과 AWS용 앱 설정을 분리하고 실제 Backend 연결
- OTP·계정 찾기·중복 가입 안내 등 인증 UX 보완
- 상담 처리 결과와 후속 안내를 고객 화면에 연결

상담사 Web

- 문의 상세와 상담 처리를 한 화면에서 이어서 확인
- 실제 Backend·격리 DB 로그인과 고객 검색 경로 확인
- 공지·운영 대시보드 API를 최신 계약에 맞게 연결

배포·데이터

- 정식 Version Tag에서만 운영 배포하도록 Gate 변경
- AI는 승인된 View만 읽고 원본 데이터 수정은 차단
- Container에 AI 계약 자산이 포함되도록 패키징 보강

검증 경계 AWS 배포와 개별 화면 연결은 확인했지만, 고객→AI→상담사→고객 전체 시나리오 독립 QA는 진행 중이다.

전체 매뉴얼에서는 Parent-Child 방식이 정답 근거를 가장 잘 찾았다

진단용 초안 · 우선 후보

Parent-Child 256 token

Child는 256 token·Overlap 32로 잘게
검색하고, 긴 Parent는 답변을 만들 때 필요한
맥락으로만 유지했다.

+16.3%p

상위 5개 정답 포함률

0건

다른 제품 근거 노출

3개 매뉴얼 · 144페이지

Positive 43 · Top-K 5 · BGE-M3 고정

청킹 방식 · token/overlap	1위 정답	상위 5개	순위 점수
Fixed 512 / 64	14.0%	62.8%	0.340
Section-aware 512 / 64	9.3%	72.1%	0.331
Parent-Child 256 / 32	27.9%	79.1%	0.492

의미: 자동 재청킹이 필요할 때의 우선 후보이며, 현재 운영 Curated Child 구조를 즉시 교체한다는 결론은 아니다.

남은 문제 근거 없음 질문은 세 방식 모두 5/7을 구분했다. 공통 실패 2건은 청킹보다 점수 기준·질문 범위 검증이 필요하다.

청킹을 고정하자 GTE가 BGE보다 검색 실패를 절반 이하로 줄였다

진단용 초안 · 개발 단계 1위

GTE multilingual base

Parent-Child-256과 동일한 43개 질의를 고정하고 모델만 바꿨을 때, 다섯 모델 중 모든 주요 순위 지표가 가장 높았다.

90.7%

상위 5개 정답 포함 · +11.6%p

9 → 4

Top-5 실패 Case

Embedding 5종 비교

Positive 43 · Parent-Child-256 · RTX 3090

모델	1위 정답	상위 5개	순위 점수
GTE multilingual base	53.5%	90.7%	0.677
Jina embeddings v3	37.2%	79.1%	0.536
BGE-M3 · baseline	27.9%	79.1%	0.492
Qwen3 Embedding 0.6B	2.3%	79.1%	0.249
Multilingual E5-base	37.2%	55.8%	0.437

추가 관찰: Qwen3는 상위 5개 포함률은 79.1%였지만 1위 정답률은 2.3%였다. 후보 회수와 최상위 순위화는 다른 문제였다.

선정 수준 GTE는 개발 단계 우선 후보이다. 점수 기준·근거 없음 질문·독립 검증 세트를 거쳐야 운영 채택을 결정할 수 있다.

개발 단계 우선 조합은 정했고, 운영 확정 전 독립 검증을 남겨두었다

01 Parent-Child + GTE 독립 검증

초안 결과를 독립 검증 세트·점수 기준·근거 없음 질문과 원시 결과 파일로 재현해 운영 채택 여부를 결정한다.

02 Handoff v2 동일 Inquiry E2E

AI 전송부터 Backend 저장·Replay·상담사/고객 Projection까지 같은 Correlation으로 확인한다.

03 HITL 재개·소비 화면 검증

Checkpoint·재처리와 Web·Mobile 승인 결과 소비를 독립 QA로 재현한다.

04 AWS 기능·안전·장애 QA

권한·데이터 정합성, Safety 우선순위, Timeout·409·Replay와 성능을 함께 기록한다.

다음 업데이트는 “개발 우선 조합의 독립 재현”과 “고객→AI→상담사→고객 전체 흐름 증거”로 닫는다.